

INTRODUCCIÓN

Data Enablement Academy



Cesar Aldana
Data Enablement Lead



David Chira
Data Enablement Lead



SOBRE MÍ



Cesar Aldana Montero
Data Enablement Lead



Estudios

Ingeniería de Sistemas UPC
Diplomado en Microfinanzas PACIFICO
CDMP, ITIL FOUNDATION, SCRUM MASTER



Experiencia laboral

Arquitecto Técnico Big Data
Consultor Gobierno y Calidad de Datos
Consultor Datawarehousing & BI



Áreas de interés

Data Lakehouse
Cloud
Data Governance



SOBRE MÍ



David Chira Siadén
Data Enablement Lead



Estudios

Ingeniero de sistemas y Computación
Master en gestión de tecnología



Experiencia laboral


Consultoría de tecnología, gestión, data y
analítica, estrategia de datos



Áreas de interés

Data, analítica, tecnología, gestión del cambio,
gestión y diseño





Qué es un Data Enabler





antes de eso... Imaginemos que estamos
construyendo una vivienda y pensemos un
poco en qué roles intervienen...





ARQUITECTO



Diseña las estructuras que tendrá la casa a partir del entendimiento de los requerimientos y necesidades del cliente. Asimismo, permanece involucrado en el proceso de construcción hasta el final



AGENTE INMOBILIARIO



Se encarga de gestionar las expectativas de los clientes, entender sus deseos y requerimientos para asesorar en la búsqueda del espacio ideal



INGENIERO CIVIL



Diseña estructuras y acabados que cumplen con la arquitectura. Las estructuras que define deben cumplir con los requerimientos de calidad y exigencias de los clientes



INGENIERO DE CONSTRUCCIÓN



Se encarga de ejecutar la construcción y mantener la infraestructura

Arquitecto



Data Architect

Encargado del diseño e implementación de la Arquitectura de Datos.

Agente Inmobiliario



Data Translator

Facilita la comunicación entre perfiles técnicos y de negocio. Promueve la adopción de una cultura analítica y de procesos.

Ingeniero Civil



Data Enabler


Diseña el modelo de datos para facilitar su consumo de forma eficiente y escalable asegurando el gobierno y calidad de la información.

Ingeniero de
Construcción



Data Engineer

Diseña y construye pipelines de datos para cargar los modelos de datos empresariales





Conociendo al Data Enabler





¿Qué capacidades debe tener un data enabler?


Capacidades en
modelamiento de
datos,
datawarehousing-b
i y data storytelling

Capacidades en
metodología de
proyectos de
Datos, gestión de
proyectos y
entendimiento del
negocio

Capacidades
en Metadatos,
Calidad y
Gobierno de
datos







¿Qué capacidades debe tener un data enabler?





¿Qué metodologías
debe conocer?




IS 8000
Calidad de
Datos






¿Qué herramientas
debe dominar?





Implementación
de iniciativas





**¿Dónde trabaja
el Data Enabler?**




Etapas y fases

2.Diseño

3. Kickoff del Proyecto
4. Integración de Proceso de Negocio
5. Proceso de Datos
6. Organización
7. Solución de Datos
8. Plataforma INCA

4.Adopción

14. Capacitación
15. Comunicaciones
16. Medición e Incentivos
17. Adopción y certificación



1. Análisis

1. Visión del Negocio
2. Proceso de Negocio


3.Construcción

9. Datos Raw
10. Datos Master
11. Explotación
12. Calidad de Datos
13. Gestión de Ciclo de Vida del Dato


5.Continuidad

18. Implementación Gobernanza/Soporte
19. Gestión del Cambio en curso
20. Gestión de Proyecto post producción (backlog)

Disponibilización de datos: Análisis y Diseño




Disponibilización de datos: Construcción - Producción



Ruta de aprendizaje

e

07 Sesiones que permiten lograr el trabajo final



TEMA 01


Modelamiento De Datos



David Chira
Data Enabler Lead



AGENDA



01

¿Por qué es importante diseñar pensando en las personas?

02

Del diseño a la práctica

03

Entornos de aplicación

04

Experiencia docet



01

¿Por qué es importante?

Las soluciones y estrategias son **diseñadas por personas para personas.**





¿Qué capacidades debe tener un data enabler?

02


Del diseño a la práctica

Concepción del prototipo hacia el **test en terreno.**





¿Cómo empezamos a modelar?






Capa Raw





Capa Master






Capa Explotación

2. Disponibilizar

3. Definir estructura de tablas.
4. Crear las tablas.
5. Publicar tablas en INCA.
6. Administrar permisos.
7. Administrar proyectos / workspace.

4. Gobernar

10. Publicar objetos en INCA.
11. Gestionar objetos en INCA.




1. Diseñar

1. Definir objetivo de la visualización.
2. Diseñar maquetado de dashboard.

3. Construir

8. Crear dashboard.
9. Publicar dashboard.

Diseñar



Diseñar




1. Describe el objetivo de la visualización o preguntas a responder:



2. Metodología



Disponibilizar



Construir

Data Visualization



1

Crea y publica dataset y visualización.



2

Conecta y explota los datos.



Power User



03

Entornos de aplicación

Solución de problemas para **diferentes entornos.**






Repasemos lo
aprendido





Resumen

Los pasos que seguiremos para diseñar una solución analítica serán:



TEMA 02


Calidad de Datos



Cesar Aldana
Data Enablement Lead



AGENDA



01

¿Por qué es importante la calidad de Datos?

02

Procesos Core de Calidad de Datos

03

Entornos de aplicación

04

Roles y componentes

05

Casos de Uso

<

>

¿Nos hacemos las siguientes preguntas?

¿Son **correctos** los datos
presentados en estos
dashboards?

¿Los datos de mi data
warehouse, big data o modelo
cuadran con la fuente?

¿Por qué el área de
finanzas tiene una cifra
de venta diferente al
área comercial?

01

Calidad de datos como percepción

Cumplir con los requerimientos de datos de los usuarios asegurando la entrega **confiable** de los activos de información (tabla, reporte, indicador)

Calidad de Datos: Salud del Dato

Data Profiling - Summary

Actualizado al: Jun 15, 2020

Prioritario: Prioritario (1) ▾

Proyecto ▾

Dataset ▾

✓ Tabla

🔍 Type to search

✓ ecai_direccion

✓ puc_ubigeos

✓ ecai_solicitante

✓ ecai_solicitud

✓ ecai_tipo_solicitante

Tablas: 5

Columnas: 47

Filas analizadas: 6,082,146

Métricas
Calculadas: 468


Cumplimiento
No Nulos 84.82%

Cumplimiento Sin
Espacios en Blanco 76.97%

Cumplimiento
Valores Unicos 29.12%


Valores Nulos

Columnas:



Celdas:

■ No cumple ■ Si cumple




Espacios en Blanco

Columnas:



Celdas:

■ No cumple ■ Si cumple



Valores Unicos

Columnas:



Celdas:

■ Si cumple ■ No cumple



Beneficios de la calidad

Eficiencia operativa/
Disminuir los costos



Incrementar
el valor



Reducción de Riesgos/
Cumplimiento Regulatorio



Agilidad



Aumentar la confianza
en la data



Activos de información

En una cultura Data Driven... Se considera a los datos como un activo estratégico, por lo que debemos cuidarlo en todo momento. Ejemplo, reportes, tablas, indicadores, conceptos de negocio, modelos, dashboards, herramientas de integración y explotación, entre otros.

Tablas



Reportes/Dashboards



Herramientas ETL, Visualización, modelamiento



Bases de Datos Fuentes de Datos



Se recomienda iniciar el proceso de gestión de calidad de datos sobre los activos críticos de la organización. Por ejemplo, reportes regulatorios, datos maestros, dashboards de dirección general

Elementos de datos

Datos consumidos por áreas o procesos de negocio de la organización. Tienen un significado para el negocio y suelen estar en más de una base de datos, varias tabla y campos

Ejemplo: celular del cliente, dirección de cliente, nombre documento, documento de identidad.

- **Elemento de Dato (ED) No Crítico:** Son consumidos por un área de negocio o por un proceso técnico sin impactar de manera directa en la decisión del negocio o en la operación
- **Elementos de datos críticos (EDC):** Tienen un alto impacto monetario, en la operación directa o en la toma de decisiones.


Usualmente son consumidos por múltiples áreas o procesos de negocio de la empresa.

Algunos ejemplos:

Columnas de tablas

Persona				
Identificación	Nombre	Apellido	Sexo	Telefono
123	Alex	Garcia	M	8281111

Campos de reportes, métricas, indicadores



Se recomienda iniciar el proceso de calidad de datos con los ED que son críticos para la compañía a nivel de impacto económico o operativo (EDC)

Los datos se organizan en dominios y elementos de datos

Dominio de datos

- Es un conjunto de datos que pueden incluir una **área completa o un conjunto específico de elementos de datos (EDs) comunes para usos o fines específicos**, que pueden ser Críticos o No críticos.
- Deben ser definidos de forma tal que **no sean objetados por otro Dueño de Información, ni sus elementos de datos (EDs) pertenezcan** a otros dominios.
- Son diseñados **para ser transversales al negocio** donde existan sinergias con otros dominios.

Tipos de Dominios de datos

Transaccional

- Típicamente orientados a transacciones o eventos: tarjetas, depósitos, préstamos, pagos, etc.
- Por lo general proceden de los sistemas origen.

■ Vinculados a datos maestros y de

Maestra / Referencia

- Datos relativamente estáticos utilizados en dominios transaccionales, derivados para realizar análisis y reportes

Derivada

- Datos agregados o calculados de múltiples dominios para casos de uso específico de la empresa.
- Incluyen datos que provienen de dominios transaccionales y

Descubrimiento

- Datos integrados requeridos para análisis exploratorio en búsqueda de *insights*
- Incluyen datos que provienen de dominios transaccionales, maestros y derivados, por ejemplo, un Análisis

Elementos de datos

- **Elemento de Dato Crítico Corporativo**: datos consumidos por procesos de negocio cross empresas del grupo. Aparecen en informes críticos y en decisiones de negocio con alto impacto en el grupo.
- **Elemento de Dato Crítico**: datos consumidos por múltiples áreas o procesos de negocio. Aparecen en informes críticos y en decisiones de negocio con impacto en datos y procesos de la organización.
- **Elemento de Dato No Crítico**: datos consumidos principal o exclusivamente por un área o proceso de negocio. Bajo impacto en los datos, procesos y decisiones

Proceso Core de Calidad de Datos



■ Actualizar repositorio

Roles y Responsabilidades

Roles	Descripción
Data Owner	Determina los requerimientos de información respecto a su dominio, es asignado a una persona en una posición de mando. Por ejemplo el data owner de contabilidad podría ser el CFO.
Business Data Steward	Conocedor del activo a nivel funcional , por ejemplo el Business Data Steward de la tabla de cuentas contables es un usuario de contabilidad.
(Table/Report/KPI) Data Operator	Principal usuario del activo de datos a nivel operativo : por ejemplo el creador de un reporte es el propietario, el que define un KPI es el propietario del KPI, el que definió la tabla es su propietario.
(Infrastructure/ Security/BI) Technical Data Steward	Responsable de ejecutar y mantener operativos los procesos técnicos que afectan (crean, modifican o eliminan) elementos de datos o activos de datos.
(Corp/Org) Data Management Lead	Principal responsable de definir, desplegar y supervisar las políticas de gobierno de datos dentro de su ámbito (empresa, corporación).
DQ Developer	Implementa técnicamente las reglas de calidad de datos.

Roles y Responsabilidades

Roles

Data Owner

Business Data Steward

(Tabla/Reporte/KPI)
Data Operator

(Infrastructure/
Security/BI)
Technical Data Steward

(Corp/Org)
Data Management Lead

DQ Developer

Principales Responsabilidades

- Establecer la **estrategia, prioridades y metas** para la calidad de datos dentro de su dominio.
- Definir, priorizar y liderar las **iniciativas de calidad de datos** dentro del dominio.
- **Aprueba** reglas de calidad de datos de **negocio** de su dominio (requisito para el pase a producción).
- **Lidera el comité** de gobierno para la parte de calidad de datos asociado a sus activos de información.
- **Planifica y prioriza** medidas correctivas sobre **incidencias de calidad de datos**.
- **Prioriza EDC** para la aplicación de reglas de calidad de datos técnicas y de negocio.
- Realizar **evaluaciones** constantes sobre las conclusiones y/o justificaciones del incumplimiento de reglas.
- **Crea/modifica/desactiva** una regla de calidad de datos (manual/carga masiva) con todos sus atributos.
- Definir la lógica y **umbrales de aceptación** sobre las reglas de calidad de datos.
- Realizar los **pases a producción** de las reglas de calidad de datos previa coordinación con el Data Operator.
- **Monitorear** de manera centralizada y consolidada las ejecuciones de los procesos asociados a las reglas de calidad de datos técnicas y de negocio.
- **Corregir los problemas de calidad de datos** relacionados a problemas técnicos.
- **Definir políticas, procesos y buenas prácticas** de gobierno y calidad de datos.
- **Coordinar, formar y guiar** a todos los data stewards.
- **Comunicar el valor** que generan las iniciativas de gobierno y calidad de datos.
- **Desarrolla** técnicamente los componentes de reglas de calidad de datos técnicas y de negocio.
- **Ejecuta y testea** la lógica de las reglas la calidad de datos y realiza un diagnóstico de la ejecución.
- Acompañamiento del pase a **producción** (ejecución automática y monitoreo de la regla).

03

Componentes de Calidad de Datos

Componentes DQ: Discovery, análisis y diseño



1 Perfilamiento de datos

Obtener estadísticas de los orígenes de datos que son candidatos a ser input en nuestro proyecto de Datos.

El análisis de los resultados determinará si incluimos la fuente o establecemos controles para mitigar los problemas de calidad de datos que han sido identificados.



2 Identificación de elementos de datos críticos (EDC)

Se consideran elementos de datos críticos (EDC) a los atributos que tienen alto impacto en el negocio y/o son usados de manera cross en la empresa (Por ejemplo, datos maestros: cliente, producto, cuenta, establecimiento, tarjeta). Es necesario organizar sesiones de trabajo con los involucrados técnicos y de negocio para identificar y priorizar los EDC a los que haremos seguimiento de calidad de datos.



3 Definición de reglas de calidad datos técnicas y de negocio

Se definen reglas de calidad de datos técnicas: duplicados, nulos, formatos, dominios válidos, rango de valores, disponibilidad, entre otros. Las reglas de calidad de datos de negocio están asociadas a reglas o especificaciones funcionales que deseamos medir y monitorear. Por ejemplo, validación de clientes válidos o colocación de tarjeta válida.

Componentes DQ: Implementación y pase a producción



4 Implementación de reglas de calidad de datos

Se desarrollan componentes a través de queries, herramientas de integración de datos u otros mecanismos. El objetivo de esta implementación es almacenar los datos de ejecución en un modelo de calidad que permita analizar los resultados para tomar acciones preventivas y correctivas mediante el dashboard de monitoreo de calidad de datos.

5 Validación y conformidad de las reglas de calidad de datos

Se da conformidad a la implementación de la regla de calidad de datos a través del análisis de los resultados, visualización y monitoreo de la regla en el dashboard de calidad de datos.

6 Soporte y pase a producción de reglas de calidad de datos

Pase a producción y habilitación de los procesos de calidad de datos y el dashboard de calidad de datos en el ambiente productivo.

Componentes DQ: Monitoreo y solución de incidencias



7 Monitoreo del Dashboard de Calidad de Datos


Monitoreo y seguimiento constante sobre las ejecuciones de las reglas técnicas y de negocio para identificar problemas de calidad de datos en los elementos de datos críticos (EDC).

8 Solución de problemas de calidad de datos

Se muestran los resultados del dashboard de calidad de datos como parte del comité de gobierno y calidad para accionar lo siguiente:

- Liderar mesas de trabajo para diseñar planes de corrección.
- Tomar acción sobre los problemas de calidad de datos.
- Monitorear y reportar el progreso de tareas correctivas.
- Planificar, priorizar y ejecutar las medidas correctivas

Componentes DQ: Pipeline Control & DQ Rules



Componentes DQ: DQ Control & Rules

PipeLine Data Control

Controles técnicos de los procesos ETL asociados a formatos, valores permitidos, entre otros. El control se aplica sobre los datos procesados durante la ejecución del pipeline con el objetivo de identificar la data que cumplió o no la validación.

Ejemplo: Validar los valores nulos y no nulos de los campos **tipo_cliente**, **num_documento** y **direccion** de la tabla personas y que los caracteres del campo **celular** sean 9.
Basta que alguna de estas columnas esté nula para **observar todo el registro**. Esta validación se realiza sobre los datos de la ejecución del proceso de carga.

Technical Data Rule

Regla de calidad de datos de completitud (nulos), conformidad (formatos, estándar), valores permitidos, longitudes, entre otros aspectos técnicos que se definen sobre las columnas de nuestras tablas raw, master, explotación para medir la calidad del dato. Esta medición se realiza sobre KPIs y umbrales de calidad de datos.

Ejemplo: Validar correo electrónico del cliente. Se validará el porcentaje de clientes sin celular en el nuevo modelo de datos Master.

Lógica: (select count(clie.email) from m_customer clie where email is not null)/ (select count(clie.email) from m_customer)

Umbral Mínimo: 85 (Mínimo permitido de aceptación para considerar incidencia de datos)

Umbral Superior: 95 (Representa una puntuación "Aceptable" para la regla establecida).

Business Data Rule

Requisitos y definiciones de negocio que tienen alto impacto a nivel de la empresa, y de las cuales se requiere medir la consistencia de datos de las estructuras que soportan dichas definiciones. Esta medición se da a través del KPIs de calidad y umbrales de calidad para determinar si el elemento de dato cumple o no la regla para alertar y tomar medidas correctivas.

Ejemplo: Validar cliente válido.

Lógica: Debe tener un registro en PUC Persona. Debe tener una cuenta activa. Debe tener una tarjeta creada

Umbral Mínimo: 85 (Mínimo permitido de aceptación para considerar incidencia de datos).

Umbral Superior: 95 (Representa una puntuación "Aceptable" para la regla establecida).

Dimensiones de la calidad de datos

Dimensiones

Descripción

1

Compleitud

Los datos relevantes para el negocio deben estar completos.

Ejemplo: validar campo dirección de tabla cliente. Si al ejecutar la regla obtenemos un 96% de cumplimiento. Esto indica que del universo total de registros, hay 96 por ciento completo y 4 por ciento vacío.

2

Conformidad / Validez

Los datos cargados son conformes a nivel de formato estándar, longitud, rangos, valores permitidos, etc.

Ejemplo: El celular cumple con el formato requerido: el registro no tiene caracteres extraños y cuenta con longitud exacta de 9 caracteres numéricos.

3

Consistencia

Los datos son consistentes en todos los repositorios o sistemas donde se usen. Es decir, los datos almacenados en las estructura de datos contemplan de manera satisfactoria las reglas de negocio definidas.

Ejemplo: Cliente válido, Venta de producto válido.

4

Precisión / Exactitud

Reflejan la realidad en cuanto a sensibilidad de datos, unidad de medidas, volumetría, tendencias, decimales, entre otros.

Ejemplo: El monto de venta debe estar en soles y expresado en decimales redondeado a 3 dígitos.

5

Duplicidad

Identificar si los datos están duplicados en nuestros datasets.

Ejemplo: El código de cliente es único para cada cliente y no existen duplicados en la tabla de clientes.

6

Integridad

Existe una relación correcta entre entidades y sus atributos, y que están disponibles para ser utilizados. La coherencia funcional de los conceptos y datos asociados y el cumplimiento de las reglas de negocio relativas a los mismos.

Ejemplo: Todas las solicitudes de evaluación crediticia tienen asociado un cliente.

03

Golden Sources

Solución de problemas para **diferentes entornos.**



Golden sources: características clave

Principios

1

Es fuente oficial

2

Versión única de la verdad

3

Diseñada para las necesidades del negocio

4

Cumple con los lineamientos de Gobierno de Datos

5

Punto de control de calidad del dato

6

Cumple modelo de datos de la organización

7

Profundidad histórica: para soportar necesidades de negocio


Descripción

- Cada fuente oficial de datos será gestionada por diferentes roles, los cuales serán responsables ante la organización
- Habrá una única fuente oficial designada para cada Elemento de Dato Crítico (EDC)
- Apoyará y priorizará igualmente los procesos de negocio de cada empresa, así como las funciones del grupo que sean necesarias
- Se gestionan según los estándares de accesos, puntos de control y uso adecuado de los datos en la organización
- Punto de medición, control y cumplimiento de la calidad de los datos
- Aporta a la calidad de los datos mediante validaciones de integridad y controles periódicos
- Tiene una relación directa con el modelo oficial de datos de las empresas del grupo, pues asegura que la ingesta lleve los valores correctos
- Enfocado en datos Transaccionales y de Referencia: almacenarán historia y versionamiento según la necesidad del negocio y/o regulaciones de cada industria o plataforma


Golden sources: roadmap hacia un modelo centralizado



Una "Golden source" por dominio de datos



Una Plataforma Central de Datos



- Facilita la identificación de responsables y el gobierno sobre las *Golden Sources*
- Arquitectura de datos simplificada que reduce riesgos o eventos críticos
- Eficiencia operativa al eliminar datos duplicados
- Simplifica la integración de diferentes iniciativas de negocio y de auditorías

- Contribuye a un fácil y rápido alineamiento con los requerimientos regulatorios de cada industria



Golden Source



Cualquier Fuente de
Datos

03

Certificación de Datos

Solución de problemas para **diferentes entornos.**



Data Certification: Resumen

Objetivo	■ Garantizar que los usuarios utilicen las fuentes oficiales y sigan las políticas de gobierno de datos.
Metodología	■ Mediante formularios y entrevistas se identifican las deficiencias. De manera recurrente se monitorea su evolución.
Periodicidad	■ Se realizará el proceso de validación similar a un proceso de auditoría interna.
Beneficios	■ Mejorar la calidad de los datos y asegurar la mejora continua.



Es necesaria la colaboración de las áreas para identificar las oportunidades de mejora. El proceso de certificación se desarrolla una vez se termina de establecer el gobierno, para facilitar la adopción y la mejora continua.

Data Certification: Preguntas Tipo

Asignación de Roles y Responsables

- ¿Se tienen identificados a los responsables de negocio?
- ¿Se ha participado en algún comité de gobierno y calidad?
- ¿Se conoce las funciones del equipo consultivo?

Uso de Fuentes Válidas

- ¿Se tiene identificado un Data Steward en el área?

- ¿El área cuenta con un inventario de fuentes?
- ¿Existe una persona responsable de cada una de las fuentes?
- ¿Todas las fuentes son consideradas Golden Sources?

Implantación de controles de Calidad

- ¿Se manipula manualmente la información?
- ¿Se tienen identificados los datos críticos?
- ¿Se han implementado KPIs sobre los datos críticos?
- ¿Se hace seguimiento de los KPIs?
- ¿Se han gestionado los planes de remediación/mitigación?

Se realizaría 2 veces al año: una online mediante formularios y una presencial mediante entrevistas.

Actualización de la Metadata

- ¿Cuántas tablas se tienen documentadas?
- ¿A nivel de campo se tiene la metadata completa?
- ¿Todas las tablas tienen un Data Operator?
- ¿Todas las tablas tienen su trazabilidad? ¿A qué nivel está documentada?

Gestión de Accesos

- ¿Se tienen medidas de control de accesos implantadas?
- ¿Se tiene documento el flujo de solicitud de accesos?
- ¿Se tienen enmascarados los datos sensibles?
- ¿Se conoce el uso de la Plataforma de Datos?

03

Flujos de Procesos de Datos

Solución de problemas para **diferentes entornos.**



Flujo del Proceso de Calidad – Perfilamiento de Datos


DEFINICIÓN DE FUENTE DE DATOS



- 1 Identificar tabla a perfilar: cliente
- 2 Seleccionar columnas a perfilar
- 3 Indicar atributos del perfilado:
 - # nulos
 - # total registros
 - %valores únicos,
 - valor mínimo
 - valor máximo
 - longitud mínima y máx
- 4 Determinar criticidad de la columna a perfilar
- 5 Configurar destinatarios para las alertas/notificaciones



SOPORTE Y PUESTA EN PRODUCCIÓN



- 6 Programar ejecuciones automáticas
- 7 Desplegar proceso en producción
- 8 Monitorear ejecuciones del componente de perfilamiento de datos

Si es un archivo propio del usuario/analista en formato csv no requiere el proceso de pase a producción

Si es Data Science se le activará la opción para subir archivos

QA Analyst tiene permiso para ejecutar y revisar la opciones

Flujo del Proceso de Calidad – Reglas de calidad técnicas

DEFINICIÓN DE REGLA TÉCNICA DE CALIDAD

- 1 Completar especificación de la regla de calidad de datos (descripciones, criticidad, umbrales, destinatarios, programación)
- 2 Enviar solicitud de creación

Asigna

IMPLEMENTACIÓN DE REGLA TÉCNICA

- 3 Recibir solicitud de creación de reglas
- 4 Desarrollar componente ETL
- 5 Testear el desarrollo construido
- 6 Programar ejecuciones automáticas
- 7 Solicitar conformidad del desarrollo

VALIDACIÓN Y APROBACIÓN DE IMPLEMENTACIÓN

- 8 Validar desarrollo implementado
- 9 Aprobar/Rechazar desarrollo

Solicita aprobación

Informa/Notifica

NOTIFICACIÓN DE REGLAS DE CALIDAD TÉCNICA

- 10 Recibir notificación de creación de regla técnica
- 13 Visualizar dashboard de calidad de datos
- 14 Alertar sobre incidencias de calidad de datos en comités

Aprueba

SOPORTE Y PUESTA EN PRODUCCIÓN

- 11 Habilitar proceso en producción
- 12 Monitorear ejecuciones de la regla de calidad de datos



(BI)
Technical Data
Steward



DQ
Developer




(Table)
Operator



(BI)
Technical Data
Steward

Flujo del Proceso de Calidad – Reglas de calidad de negocio



03

Data Profiling

Solución de problemas para **diferentes entornos.**



Perfilamiento de Datos

Análisis de estructuras y contenido utilizando técnicas estadísticas para presentar patrones de los datos. El perfilamiento de datos debe ser el primer paso en la fase de análisis y diseño (Discovery de inputs) de un proyecto de Data. Además, se recomienda automatizar las reglas tanto como sea posible.

Profile_Customer_Demo - Column Profiling											Values					Patterns	Statistics			
Name	Unique V...	% Unique	NULL	% Null	Datatype	% Inferred	Documented Dat...	Minimum...	Maximu...	Last Profile Ru	Value	Frequ...	Percent	Chart	Drill down					
Source Name											NULL	4	33.33		↕					
CUST_ID	12	100.00	-	-	String(5)	100.00	string(8)	1234	A123	Mar 2, 2014 1:15:	Springfield	2	16.67		↕					
COMPANY	5	41.67	-	-	String(10)	100.00	string(15)	ABC INC	STOP 'N ...	Mar 2, 2014 1:15:	Denver	2	16.67		↕					
CONTACT	11	91.67	-	-	String(15)	100.00	string(23)	BILL WH...	WILLIAM...	Mar 2, 2014 1:15:	San Diego	1	8.33		↕					
TITLE	6	50.00	-	-	String(20)	100.00	string(30)	ANALYST	SR. DIR...	Mar 2, 2014 1:15:	SD	1	8.33		↕					
ADDR1	12	100.00	-	-	String(17)	100.00	string(26)	123 MAI...	834 2nd ...	Mar 2, 2014 1:15:	SAN DIEGO	1	8.33		↕					
ADDR2	7	58.33	4	33.33	String(11)	100.00	string(17)	Denver	Springfield	Mar 2, 2014 1:15:	Los Angeles	1	8.33		↕					
ADDR3	6	50.00	4	33.33	Fixed Length Stri...	100.00	string(5)	MO	ca	Mar 2, 2014 1:15:										
ADDR4	6	50.00	5	41.67	Integer(5)	100.00	number(8)	62223	92121	Mar 2, 2014 1:15:										
COUNTRY	1	8.33	-	-	Fixed Length Stri...	100.00	string(5)	USA	USA	Mar 2, 2014 1:15:										
PHONE	7	58.33	6	50.00	String(13)	100.00	string(20)	(858)55...	8585555...	Mar 2, 2014 1:15:										
EMAIL	8	66.67	3	25.00	String(20)	100.00	string(30)	JSMITH...	ww@abc...	Mar 2, 2014 1:15:										

- ¿Cuántos nulos hay?
- ¿Cuántos duplicados hay?
- ¿Cuántos valores repetidos hay?
- ¿Cuál es el valor máximo y mínimo?
- ¿Se utilizan bien los tipos de datos?

Estos datos sirven como input para decidir si se considera o no la fuente analizada para mi proyecto de Data.

También, nos permite tener una primera aproximación para establecer las reglas de transformación, formato y limpieza

Dashboard de Data Profiling: Reglas Clave

Data Profiling - Core Rules



Fecha de Ejecución		Proyecto		Dataset		Tabla		Prioritario: Prioritario (1)		Validaciones	
Tabla	Columna	Unicos			Nulos		Espacios en blanco				
		No Cumple	Si Cumple	Si Cumple	No Cumple	% Cump	Si Cumple	No Cumple	% Cump		
puc_ubigeos	DES_UBIGEO	538	1,520	2,058	0	100	614	1,444	29.83		
	DPT_UBIGEO	2,058	0	2,058	0	100	2,058	0	100		
	DST_UBIGEO	2,051	7	2,058	0	100	2,058	0	100		
	PRV_UBIGEO	2,058	0	2,058	0	100	2,058	0	100		
ecai_tipo_solicitante	ID_TIPO_SOLICITANTE	0	2	2	0	100	2	0	100		
	NOMBRE_TIPO_SOLICITANTE	0	2	2	0	100	2	0	100		
ecai_solicitud	CAMPANA	1,216,388	4	1,213,599	2,793	99.77	1,213,599	0	99.77		
	FEC_TARJ_ANULADA	1,216,392	0	0	1,216,392	0	0	0	0		
	FINANTIENDA	1,216,388	4	1,216,388	4	100	1,216,388	0	100		
	LINEA_ASIG	1,216,289	103	1,174,197	42,195	96.53	1,174,197	0	96.53		
	LINEA_PROMEDIO	1,153,643	62,749	1,206,766	9,626	99.21	1,206,766	0	99.21		
	MOT_DESI_FINAL	1,216,391	1	1,216,382	10	100	1,216,382	0	100		

Dashboard de Data Profiling: Reglas Clave

Data Profiling - Core Rules



Fecha de Ejecución Proyecto Dataset Tabla Prioritario: Prioritario (1) Validaciones									
Tabla	Columna	Unicos			Nulos		Espacios en blanco		
		No Cumple	Si Cumple	Si Cumple	No Cumple	% Cump	Si Cumple	No Cumple	% Cump
puc_ubigeos	DES_UBIGEO	538	1,520	2,058	0	100	614	1,444	29.83
	DPT_UBIGEO	2,058	0	2,058	0	100	2,058	0	100
	DST_UBIGEO	2,051	7	2,058	0	100	2,058	0	100
	PRV_UBIGEO	2,058	0	2,058	0	100	2,058	0	100
ecai_tipo_solicitante	ID_TIPO_SOLICITANTE	0	2	2	0	100	2	0	100
	NOMBRE_TIPO_SOLICITANTE	0	2	2	0	100	2	0	100
ecai_solicitud	CAMPANA	1,216,388	4	1,213,599	2,793	99.77	1,213,599	0	99.77
	FEC_TARJ_ANULADA	1,216,392	0	0	1,216,392	0	0	0	0
	FINANTIENDA	1,216,388	4	1,216,388	4	100	1,216,388	0	100
	LINEA_ASIG	1,216,289	103	1,174,197	42,195	96.53	1,174,197	0	96.53
	LINEA_PROMEDIO	1,153,643	62,749	1,206,766	9,626	99.21	1,206,766	0	99.21
	MOT_DESI_FINAL	1,216,391	1	1,216,382	10	100	1,216,382	0	100

Dashboard de Data Profiling: Reglas Customizadas

Data Profiling - Customized Rules



Fecha de Ejecución

Proyecto

Dataset

Tabla

Prioritario: Prioritario (1)

Validaciones

Tabla	Columna	Email			Número			Fecha		
		No Cumple	Si Cumple	% Cump	No Cumple	Si Cumple	% Cump	Si Cumple	No Cumple	% Cump
ecai_solicitud	FEC_TARJ_ANULADA	-	-	-	-	-	-	0	0	0
	NUM_ENT_DEUDORAS	-	-	-	0	0	0	-	-	-
	NUM_SOLICITUD	-	-	-	17	1,216,371	100	-	-	-
	NUM_TARJETA	-	-	-	0	0	0	-	-	-
ecai_solicitante	NUM_DOCUMENTO	-	-	-	10	1,410,666	57.98	-	-	-
	SALDO_TC	-	-	-	0	1,206,754	49.6	-	-	-
ecai_direccion	CORREO_ELECTRONICO	2,430,796	0	0	-	-	-	-	-	-
	NUMERO_DIRECCION	-	-	-	2,430,796	0	0	-	-	-
	NUM_CELULAR	-	-	-	2,430,796	0	0	-	-	-

Dashboard de Data Profiling: Datos de Ejemplo

Data Profiling - Sampling						
Fecha de Ejecución	Proyecto	Dataset	Tabla	Tipo Medición: Repetidos (1)	Prioritario: Prioritario (1)	
Tabla	Columna	Cumplimiento	Valor Muestra	Repetición...	..	
puc_ubigeos	PRV_UBIGEO	18.12%	01	373		
puc_ubigeos	DST_UBIGEO	10.69%	00	220		
puc_ubigeos	DPT_UBIGEO	9.09%	02	187		
puc_ubigeos	DES_UBIGEO	0.49%	SANTA ROSA	10		
ecai_tipo_solicitante	NOMBRE_TIPO_SOLICITANTE	50.00%	Solicitante	1		
ecai_tipo_solicitante	ID_TIPO_SOLICITANTE	50.00%	2	1		
ecai_solicitud	TIPO_PRODUCTO	100.00%	1	1216376		
ecai_solicitud	TASA_INTERES	100.00%		1216392		
ecai_solicitud	SCORE_BURO	23.24%	0.0	282652		
ecai_solicitud	PRODUCTO	99.89%	TC	1215019		
ecai_solicitud	NUM_TARJETA	100.00%		1216392		
ecai_solicitud	NUM_SOLICITUD	+0.00%	7849140	18		
ecai_solicitud	NUM_ENT_DEUDORAS	100.00%		1216392		
ecai_solicitud	NOM_CORTO_TARJ	100.00%		1216392		
ecai_solicitud	MOT_DESL_FINAL	52.82%	Otro	642542		

03

Reglas de Calidad de Datos

Solución de problemas para **diferentes entornos.**




Reglas técnicas y de Negocio

Las reglas de calidad de datos nos permiten medir y monitorear la salud de nuestros datos conforme a definiciones técnicas y de negocio propios de nuestra empresa. Por ejemplo, para reglas técnicas podríamos validar que el monto de venta siempre sea mayor a 0 o que las columnas de nuestra tabla de clientes no contengan nulos, duplicados o que siempre cumplan con el formato especificado. Por otro lado, las reglas de negocio nos permiten validar temas de consistencia asociadas al cumplimiento de reglas de nuestro negocio, por ejemplo, una venta no debe ser considerada como válida si es que no tiene un cliente con cuenta activa asociada a la transacción.

Componentes de la solución

- Especificación funcional de la regla de calidad de datos técnica o de negocio (Data Owner o Technical Data Steward)
- Data Quality Model en BigQuery
- Componentes técnicos para cargar el Data Quality Model (matilium, procedures, datafusion, entre otros).
- 2 dashboards en Google Data Studio (Vista ejecutiva y operativa)


DQ Specification




DQ Pipelines



DQ Model



Dashboards




Reglas técnicas y de Negocio

Executive Dashboard

Vista ejecutiva que muestra la salud de los datos a partir de las reglas técnicas y de negocio que han sido definidas por los usuarios o cómo parte de los proyectos de Data en nuestra organización. El tener esta vista resumida nos permite conocer rápidamente como vamos avanzando en temas de calidad de datos. A continuación, se mencionan los principales KPIs/Dimensiones del dashboard:


- **% Cumplimiento:** Promedio de la última ejecución de todas las reglas de calidad de datos. La métricas base para el cálculo son: Filas válidas / Total de Filas.
- **Reglas ejecutadas:** Cantidad de reglas ejecutadas en el último periodo.
- **Cientes, Personas y Transacción:** Representan los dominios funcionales que agrupan las reglas de calidad de datos. Se definen como parte del gobierno de datos y los usuarios de técnicos y de negocio.
- **Prioridad y dimensión de calidad de datos:** Definiciones funcionales que representan agrupaciones de las reglas de calidad de datos para la visualización.



Operational Dashboard

Vista operativa que muestra el total de filas analizadas, filas válidas, filas no válidas y el % de cumplimiento por cada regla técnica y de negocio. A continuación, se mencionan las principales variables y métricas:





- **% Cumplimiento:** Filas válidas / Total de filas analizadas para la última ejecución del día
- **Filtro año-mes ejecución:** Año y mes en que se ejecutó la regla
- **Filtro día de ejecución:** Día en que se ejecutó la regla
- **Proyecto y dataset:** Representan las tablas base usadas para el cálculo de las reglas.
- **Dominio y tipo de regla:** Definiciones funcionales que representan agrupaciones de las reglas de calidad de datos para la visualización.




Reglas ejecutadas: 22

Dominio

Tipo de Regla



Baja: Datos que tienen un impacto en tablas raw o catálogos que no son principales.



Rangos: Qué valores o resultados se salen fuera de los rangos permitidos


Capa	Tabla	Cumplimiento
1. Master	t_sale	0 %
2. RAW	puc_emails,puc_...	0,5 %
3. RAW	m_customer	33,99 %
4. Master	m_customer	42,16 %

1 - 5 / 5

Explotación: Contiene los tableros de explotación y tablas de análisis y reportes de usuarios finales.

Score **Bajo** (<85%)

Dashboard de Calidad de Datos: Vista Operativa



04

Experientia docet

Aprendemos de la experiencia, **impulsemos
la experimentación.**





Listos para
empezar



TEMA 02


Gobierno de Datos



Cesar Aldana
Data Enablement Lead



AGENDA



01

¿Por qué es importante la calidad de Datos?

02

Procesos Core de Calidad de Datos

03

Entornos de aplicación

04

Roles y componentes

05


Casos de Uso





Próximos pasos

Cada sesión abordará diversos temas para diseñar una solución. Empezaremos por:





Gracias



Cesar Aldana Montero
David Chira

