

Manual de Uso Framework de despliegue ITC Dataops

1. Definición

El framework de despliegue ITC Dataops se encarga de cubrir la necesidad de despliegue de componentes y servicios en GCP, de forma automatizada y evitar despliegues manuales.

2. Prerrequisitos de uso del framework

HABILITAR APIS.

cloud build
workflows
job scheduler
cloud functions
cloud run
aiplatform

CREAR ROL CUSTOMIZADO DE HABILITACIÓN DATAOPS

Para desplegar Dataops se debe tener el yaml: xops_enabler_role el cual contiene todos los permisos necesarios,, en caso contrario la cuenta de servicio debe tener los siguientes Roles:

Artifact Registry Administrator
Cloud Build Service Account
Cloud Run Admin
Cloud Scheduler Admin
Logs Writer
Monitoring Editor
Service Account User
Storage Admin
Viewer
Workflows Admin

3. Reglas y Validaciones

1. No se aceptan script que contengan sentencias de DROP TABLE.
2. Si la tabla existe y se envía un CREATE OR REPLACE sobre la tabla en la sección DML, no se ejecuta el DDL. La tabla debe ser previamente eliminada manualmente por el Data Operator.

3. Las sentencias DML solo pueden ejecutarse en ambiente de desarrollo. El framework no ejecuta DML en ambientes de producción.
4. Los DML en ambiente de desarrollo pueden usarse para enviar llamadas (CALL) a Stored Procedures para probar su ejecución.

4. Configuración para el uso del framework

4.1. Definición del repositorio

El repositorio será donde se suban todos los scripts que forman parte del pase: .sql, .yaml, etc. El framework es agnostico al repositorio que se utilice. Por default utilizamos Source Repository de GCP, pero se puede usar Github o cualquier otro, en estos casos se debe generar un link tokenizado para que el motor de cloud build pueda realizar el git clone según el valor que se le proporcione en la variable `_URL_REPO`

4.2. Uso del archivo deploy

1. Dentro del repositorio, crear una carpeta llamada deploy.
2. En la carpeta deploy, agregar un archivo JSON con la siguiente forma:

```
{
  "bigquery_ddl": [
  ],
  "bigquery_sp": [
  ],
  "bigquery_dml": [
  ],
  "image": [
  ],
  "cloud_run": [
  ],
  "cloud_function": [
  ],
  "workflow": [
    "/pipeline/workflow/campaign/farmas-recommendation-model-csml.yaml"
  ],
  "vertex_pipeline": [
    "/service/vertex/itc-recommendation-ml-model/deploy_config_inference.yaml"
  ],
  "pubsub": [
  ],
  "matillion": [
  ],
  "matillion_json": [
  ],
  "cloud_scheduler": [
  ]
}
```

Donde:

- **bigquery_ddl**: van listados las rutas de cada script DDL
 - **bigquery_sp**: van listados las rutas de los store procedures
 - **bigquery_dml**: van listados los scripts de los DML a ejecutar
 - **image**: Yaml definición para la construcción de imágenes que sirve para cloud runs o para job vertex
 - **cloud_run**: Yaml de definición de cloud run a desplegar.
 - **cloud_function**: Yaml de definición de cloud run a desplegar
 - **vertex_pipeline**: Yaml de definición pipelines a desplegar en vertex ai
 - **workflow**: Listado de Workflows a desplegar.
 - **cloud_scheduler**: Definiciones de programaciones en Cloud Scheduler.
3. Antes de ingresar a la carpeta deploy, asegurarse de tener los archivos en el repositorio.
 4. El nombre del Workflow definido en el archivo se desplegará con el prefijo dev-, por ejemplo, si el archivo es nombre.yaml, el Workflow se creará como dev-nombre.

4.3. Creación del Trigger (activador) en Cloud Build

1. Acceder al proyecto **itc-data-devops-01** en Google Cloud.
2. Utilizar la región **us-central1** por default.
3. Configurar los siguientes parámetros:
 - **Evento**: Invocación manual.
 - **Repositorio del framework**:
cloud-itc-dataops-01/itcm-dp-dataops-build (GitHub)
 - **Revisión**: Rama dev o prd segun la versión del framework que se desee utilizar.
 - **Configuración**: Tipo Cloud Build (formato YAML o JSON).
 - **Ubicación del archivo yaml**:
Para desplegar en desarrollo
/build/cloudbuild_sourcerepository_dev.yaml.

Para desplegar en producción
/build/cloudbuild_sourcerepository_prd.yaml.

Para desplegar desde cualquier otra rama usuaria
/build/cloudbuild_sourcerepository_user.yaml.
 - **Variables de la ejecución**:

_ABREV_EMPRESA: abreviatura de la empresa.

_DATAOPS_VARIABLES: Relacion de Variables de despliegue y sus valores en formato “nombre_variable=valor”. Ejemplo:

```
inca_cloudsql_instance=dev-intercorp-data-operation:us-central1:dev-itcbi-lake-csql-usct1-fcys
proyecto_farmas_input=qa-itc-customer-services
dataset_farmas_input=input_farmas_tables
tabla_farmas_dv_productos=dv_productos
tabla_farmas_dv_fact_cupones_demanda=bi_comercial_dv_fact_cupones_demanda
tabla_farmas_dv_locales=dv_locales
tabla_farmas_ba_resumen_variable_cupon_digital=ba_resumen_variable_cupon_digital
tabla_farmas_dv_campanias=dv_campanias
tabla_farmas_dv_modulo_prioridad=dv_modulo_prioridad
schema_pg_customer_recommendation=customer_recommendation
mail_pubsub_project=central-data-governance-260223
mail_pubsub_topic=itcm-mail
dblink_pg=dev-intercorp-data-operation.us.connx_cust_recommendation
```

_PROJECT_ID: Proyecto por default si es que no se indica el project en los yaml

_REPO_NAME: Nombre del repositorio en Source repository.

_REPO_PROJECT_NAME: Proyecto donde se ubica el repositorio en gcp

_URL_REPO: URL tokenizada del repositorio si es un repositorio fuera de Source repository, por ejemplo en Github.

_SERVICE_ACCOUNT_ID: Cuenta de servicio por default si no es indicado en el yaml del componente. Ejemplos:

- dev-[abrev empresa]-operation-processing: cuenta de servicio con permisos necesarios para ejecutar workflows, cloud functions, también debe tener acceso para lectura y escritura sobre bigquery etc.
- dev-[abrev empresa]-storage: cuenta de servicio con permisos sobre bigquery y cloud storage

Ejemplo de configuración de variables

Variable 1 * _ABREV_EMPRESA	Value 1 itc
Variable 2 * _DATAOPS_VARIABLES	Value 2 tabla_m_product= intercorp_data_storage_pv_m aster_product_m_product tabla_valid_customer= intercorp_data_storage_pv_bi _vuc_insight_ba_itc_valid_cus tomer tabla_t_experience_transactio n= intercorp_data_storage_pv_m aster_transaction_t_experien ce_transaction
Variable 3 * _PROJECT_ID	Value 3 dev-itc-customer-services
Variable 4 * _REPO_NAME	Value 4 itcm-inca-audience-
Variable 5 * _REPO_PROJECT_ID	Value 5 itc-data-devops-01
Variable 6 * _SERVICE_ACCOUNT_ID	Value 6 dev-farmas-cupones-inca- job@dev-itc-customer- services.iam.gserviceaccount.c om

4. Configurar la cuenta de servicio:

- trv-itcbi-devops-app@itc-data-devops-01.iam.gserviceaccount.com.
- En algunos casos, será necesario otorgar permisos adicionales a esta cuenta de servicio para que pueda acceder a las funciones necesarias.

4.4. Ejecución y Validación

1. Guardar la configuración del activador y activarlo manualmente.
2. Verificar el despliegue revisando los registros de Cloud Build.
3. En el caso del Workflow, validar que se haya creado con el nombre correcto en Google Cloud.
4. Confirmar que los ddl y Store Procedures se hayan creado correctamente en BigQuery

5. Detalle de Configuración y reglas por tipo de componente

5.1. Scripts ddl

- Extensión necesaria de archivo: .sql
- El estándar de desarrollo para el nombramiento de la tabla y los campos va en el standard de bigquery
- El contenido del script debe empezar con CREATE OR REPLACE TABLE o CREATE TABLE
- Al ejecutar el Trigger, el framework valida la existencia de la tabla, si esta ya existe no se ejecutará el CREATE TABLE para evitar la pérdida de datos. Cualquier modificación a la tabla debe realizarse por otro flujo de solicitud de backup de data y alter table con el equipo de operaciones previo al pase.

5.2. Store procedures

- Extensión necesaria: .sql
- Debe iniciar con CREATE OR REPLACE PROCEDURE.
- No debe contener sentencias de eliminación de datos sin validaciones previas.
- Se debe documentar los parámetros de entrada y salida.

```
BEGIN
  DECLARE var_uri STRING;
  SET var_uri = "[gs://ruta-bucket/nombre_archivo.csv]";

  TRUNCATE TABLE `proyecto.dataset.tabla_destino`;

  EXECUTE IMMEDIATE FORMAT("""
    LOAD DATA INTO `proyecto.dataset.tabla_destino`
    FROM FILES ();

  """);
END;
```

5.3. Workflows